João Roberto de Oliveira Felix

Classificação de tópicos da Vício

Etapa complementar | Relatório final M8 | 22 de outubro de 2026

Resultado: Large + sinais foi a receita escolhida. Acertou 53/80 sugestões por ramo no desenvolvimento e 13/20 no diagnóstico já conhecido. As 559 questões seguem para revisão. A meta de precisão de 95% com cobertura não foi atingida; sem publicações, a precisão é indefinida.

Sistema construído

O programa recebe 659 questões, a árvore e 100 referências humanas. Limpa HTML e normaliza campos, preservando IDs e hashes. Disciplina e assunto de origem não entram como verdade nem atributo. Só concorrem 371 temas ativos abaixo das raízes. A decisão final usa código numérico próprio e caches: nenhuma chamada a modelo de linguagem ou encoder.

Componente	Função e procedência
Catálogo	Descrições e termos para 371 temas, com fontes e ambiguidades; 88 âncoras de leis/artigos para 87 temas. Preparação por LLM somente sobre taxonomia e fontes, sem consultar classificações de questões.
Representação	TF-IDF do catálogo; E5-small FP32 de 384 dimensões e alternativa E5-large INT8 de 1024, preparados localmente. As receitas Large também requerem vetores Small. Texto longo usa janelas, sem corte silencioso. Versões e hashes estão nos manifestos.
Ordenação escolhida	Ranking supervisionado por pares, com regularização e peso igual por questão. Aprende com centrais e extras humanos; o escore não é probabilidade. Variantes com sinais usam normas, artigos, termos e títulos. Uma referência legal é evidência textual, não validação jurídica.
Confiança e publicação	Logística regularizada com nove atributos, ajustada em previsões fora do treino. Dezoito regras por receita com suporte mínimo 10 e precisão observada mínima 95%; validação externa antes de habilitar a política.

A variante hierárquica recua ao ancestral comum mais específico dos três primeiros candidatos, quando ativo, não raiz e não genérico. Níveis e recuos são registrados. As referências de classificação são exclusivamente as 100 fornecidas pela equipe, sem rótulos artificiais ou classificação manual das questões. Não houve revisão jurídica humana dos descritores.

Fontes: catálogo, âncoras, protocolo, encoder maior. E5-large: revisão 3d7cfbdacd47fdda877c5cd8a79fbcc4f2a574f3, licença MIT. INT8 oficial executado em AVX2; não se presume equivalência ao FP32.

Avaliação, escolha e previsão

As 100 referências têm 92 questões dentro da árvore, oito fora, 61 temas centrais e 39 questões com extras. Todas vêm do banco anterior; não há referência recente disponível. O acerto aceita central, extra ou ancestral/descendente de um deles; irmãos contam como erro.

Grade fixada antes da medição M8

Receita	Acerto por ramo	Exato / top 5
Híbrido original M3	37/80	24 /54
M7 preservado	54/80	42 / 66
Large + fusão RRF	50/80	35 / 68
Large + sinais (escolhida)	53/80	39 / 67
Large + sinais + hierarquia	54/80	38 / 67
Small + sinais	53/80	38 / 66
Small + sinais + hierarquia	54/80	38 / 66

A regra fixada prioriza cobertura elegível, precisão e depois acerto global. Na seleção interna, Large + sinais com confiança mínima 0,90 teve 14/14 aceitas corretas (17,50% das 80). RRF também teve 14/14, mas perdeu no desempate: 50/80 contra 53/80. M7 tinha 54/80, sem grupo elegível. Portanto, a escolhida não melhorou o acerto global: perdeu um acerto frente ao M7.

Em três blocos externos, receita, regra e confiança são ajustadas apenas no treino. O procedimento teve 54/80 acertos por ramo, 43 exatos e 66 no top 5. As regras candidatas aceitaram 4/80 (5,00%), com 4/4 acertos e Wilson 95% de 51,01% a 100,00%. São menos de 10 aceitos: a política final ficou desabilitada. Origem: bloco 1: M7 preservado aceitou 0; bloco 2: M7 preservado aceitou 0; bloco 3: Large + fusão RRF aceitou 4. Os 4/4 vieram do RRF; não validam diretamente a receita final nem repetem o resultado interno de 14/14.

Na confiança externa, Brier=0,2074 contra 0,2210 da constante ajustada no treino; ECE=0,0852 contra 0,0340, em cinco faixas. Menor é melhor em ambos: o Brier melhorou, o ECE piorou. O resultado misto não certifica probabilidades individuais.

Limites da evidência e entrega

As 80 referências orientaram módulos anteriores; as 20 reservadas já eram conhecidas. A validação aninhada separa esta seleção, sem apagar a adaptação histórica. O cross-fit interno compartilha treinos dos rankers. O diagnóstico das 20 veio depois da escolha: 13/20 por ramo e 17/20 no top 5; não é um teste independente novo.

O CSV reúne 80 predições externas aninhadas,20 do diagnóstico e 559 da execução final. O ranking final é reajustado nas 100 referências; a confiança usa apenas as previsões fora do treino das 80. Esse reajuste não recebeu teste independente novo. A previsão exclui as 100 referências: cobertura=0/559. A precisão real das 559 é desconhecida; intervalo de Wilson exploratório não cobre adaptação ou mudança de distribuição. Se não há publicadas, TXT usa zero como sentinela e JSON registra null.

Fontes: métricas, diagnóstico das 20, previsão. Não são resultados de um novo teste independente.

Diagnóstico e operação

O que ainda atrapalha

A árvore original tem 337 descrições de parentesco, 20 vazias e oito grupos de títulos repetidos. O enriquecimento melhora a representação, mas não estabelece a convenção editorial da equipe. Recortes ambíguos como Parte 1/2 continuam sem fronteiras inventadas. Os 100 exemplos cobrem apenas 61 centrais, o que limita o aprendizado de distinções finas.

Na seleção externa das 80, a comparação estrutural encontrou 6 erros em outra disciplina, 11 em outro ramo da mesma disciplina, 3 em tema irmão e 6 referências fora. Em 12 erros havia destino aceito no top 5; em 14 casos não havia, incluindo fora. São relações da árvore, não causas jurídicas demonstradas por IA.

As intervenções propostas são critérios de inclusão/exclusão para temas próximos, exemplos humanos por recorte e avaliação temporal recente. Baixa confiança encaminha à revisão; não prova que a questão é fora da taxonomia. Extras não são automatizados sem avaliação própria.

Cenário de 50 mil questões por semana

As medidas locais usam Windows e CPU. Uma execução em ambiente compartilhado não é teste de carga de produção. A projeção abaixo é linear, com textos e catálogo semelhantes, sem paralelismo; vetores já existentes não precisam ser preparados novamente.

Fase	Medida local	Projeção para 50 mil
Preparação Small	316,5 s /1010 registros	4,35 horas; aproximação com questões e temas misturados
Preparação Large adicional	331,3 s /64 questões (67 janelas)	71,89 horas adicionais; extrapolação linear condicional
Decisão com vetores prontos	330,7 s para 559; carga separada: 23,5 s	8,22 horas só de inferência
Revisão humana	Hipótese: 2 min por questão revisada; cobertura mantida	1666,7 horas de revisão

Large também exige Small: cenário somado de 76,24 horas. Large usa 64 questões contíguas não aleatórias, por timestamps de arquivos em host compartilhado; não garante representatividade e exclui carga inicial e reaproveitamento de cache. A duração integral desde zero permanece desconhecida. Não houve custo de API. Computador, energia e revisão têm custo: horas-máquina vezes tarifa mais horas de revisão vezes custo do especialista. O tempo humano é hipótese, não duração medida.

Em produção, processar em lotes e liberar caches de consultas para limitar RAM. Cada correção registra central, extras ou fora, justificativa, revisor e versões. Avaliar candidatos semanalmente com novas correções e teste temporal separado; promover só com precisão e cobertura sustentadas, preservando a versão anterior. Essa operação é proposta, não serviço implantado.

Para regenerar CSV e previsão, na pasta etapa-complementar: **python -E -X utf8 -B -S scripts/entregar_precisao.py**. O README separa esse comando da reconstrução dos embeddings e do PDF. A verificação em cópia bloqueia rede, credenciais, encoders e pesos.

Fontes: benchmark, diagnóstico estrutural, preparação Small, execução Large, intervalos Large. Projeções não garantem capacidade.

Memo para o professor

Para: equipe responsável pelos temas e pela revisão de questões
De: João Roberto de Oliveira Felix
Assunto: critérios dos temas, revisão e próxima validação

O que encontramos

Melhorar as descrições do catálogo ajudou o sistema a encontrar destinos mais coerentes com as classificações da equipe. Na rodada final, a avaliação do procedimento em 80 referências acertou 54 primeiras sugestões; em 66 havia um destino aceito entre as cinco opções. Esses exemplos já foram usados em desenvolvimento, portanto os números não garantem o mesmo resultado em questões novas.

A entrega encaminha todas as 559 questões à revisão. Ainda não há evidência suficiente para publicação automática com 95% de precisão. A sugestão pode ajudar na triagem, mas a confiança estimada não substitui sua decisão em um caso incerto.

O que recomendamos mudar nos temas

Começar pelos títulos repetidos, descrições sem definição temática e recortes como Parte 1/2. Para cada destino, escrever o que entra, o que não entra e como se distingue dos temas próximos. Incluir exemplos e contraexemplos revisados pela equipe. Informar se um nó aceita questões diretamente ou apenas organiza subtemas.

Não recomendamos juntar temas automaticamente porque seus nomes são parecidos. Quando forem o mesmo destino de estudo, a equipe pode estabelecer um nome principal e redirecionamentos. Quando forem recortes diferentes, a fronteira precisa ser explícita. Toda alteração deve ter versão e mapa dos IDs, preservando o histórico das questões.

As descrições e referências de leis preparadas nesta entrega são insumos para o sistema, sem revisão jurídica humana. Elas não resolvem sozinhas a convenção editorial. Uma citação de lei ou artigo também não determina, por si, o assunto central de uma questão.

Apoio necessário da equipe

Priorizar uma amostra de questões recentes, sem usar todas imediatamente para corrigir o sistema. Guardar parte para uma avaliação futura separada. Incluir temas com poucos exemplos, fronteiras entre temas próximos e situações em que nenhum destino serve. Em parte da amostra, dois revisores podem classificar independentemente e resolver divergências.

Registrar o tema central, os temas adicionais aceitos, o motivo da correção e eventual lacuna da árvore. Distinguir erro da sugestão, informação ausente, ambiguidade da convenção e ausência de tema. Nas 100 referências,39 possuem assuntos adicionais; uma regra comum para central e extras ajudará tanto o treinamento quanto a revisão.

Recomendação: limitar o piloto à capacidade da equipe e ampliar a automação somente após confirmar precisão de pelo menos 95% em uma avaliação humana recente, com quantidade de casos e cobertura explicitadas. O principal próximo ganho deve ser demonstrado na redução de revisão sem aumentar publicações erradas.