Classificar para publicar com crit rio

Case V cio | Roberto Felix | 16 de outubro de 2026

Entrega: 359 decis es, 77 publica es, 278 revis es e quatro quest es fora do recorte. A cobertura 21,45%. A meta de precis o jur dica de 95% ainda n o foi comprovada. A solu o torna expl citos os motivos de reten o, preserva o hist rico e permite reproduzir a entrega sem novas chamadas.

1. Racioc nio e escolhas

O erro mais caro colocar a quest o no t pico errado para o aluno. Comecei pela integridade dos textos e da rvore, separei o assunto central dos assuntos acess rios e tratei a possibilidade de recusar publica o como parte da solu o. Os campos de origem foram preservados para diagn stico, mas exclu dos do prompt: n o s o r tulos confi veis.

Usei o cat logo completo dos 375 n s ativos no primeiro classificador. Assim, a escolha inicial n o depende de uma busca que poderia esconder o tema correto. Escolhi Gemini 3.5 Flash-Lite, com racioc nio MEDIUM, por funcionar no acesso gratuito dispon vel; n o houve compara o que demonstrasse superioridade sobre outros modelos. A resposta estruturada registra central, extras, alternativas, evid ncia textual, confian a e necessidade de revis o.

Hip tese / tentativa	Evid ncia e decis o
O contexto completo evita classifica es pelo t tulo isolado.	Limpeza de HTML e composi o de enunciado, comando e alternativas; n o reconstru texto ausente nem corrigi OCR por adivinha o.
Pedir aten o expl cita ambiguidade ajuda a reter casos arriscados.	Nos mesmos 20 casos de desenvolvimento, o prompt v2 pediu dez revis es, contra tr s no v1. Ambos produziram 20 respostas v lidas. Escolhi v2 pela triagem, sem alegar ganho de precis o.
Confian a alta basta para publicar.	Descartada como regra nica: confian a n o foi calibrada. A pol tica tamb m bloqueia candidatos concorrentes, raiz gen rica, colis es entre ramos, excesso de extras e revis o solicitada.
Um segundo passe pode liberar casos retidos s por alternativas.	Nos 41 selecionados, houve 23 propostas; 20/23 coincid ncias estritas e uma diverg ncia expl cita. O crit rio previamente registrado falhou; nenhuma promo o foi adotada.

O que foi implementado

Python com biblioteca padr o: prepara o, valida o de IDs e evid ncias, API com pausas, recibos com checksum e retomada, pol tica de decis o, exporta o, revis o cega por IA e avalia o. A pol tica v1 exige confian a autodeclarada de pelo menos 0,95, no m ximo um extra e aus ncia dos bloqueios; foi registrada ap s o piloto, antes da inspe o dos novos resultados do lote. N o rebaixei o limiar para melhorar cobertura.

Revis es por agentes Codex apoiaram a auditoria e as exce es; n o equivalem a especialistas jur dicos. N o implementei embeddings, treinamento supervisionado ou agentes aut nomos na classifica o de produ o. S o op es a testar ap s obter refer ncia confi vel.

Fontes: pol tica v1, pilotos, experimento controlado. Os 20 casos do piloto s o desenvolvimento, n o amostra de valida o independente.

Os dados tamb m precisam de decis es editoriais

2. Diagn stico do recorte

A rvore tem 377 registros, dos quais 375 est o ativos, incluindo quatro ra zes de disciplina. N o h IDs repetidos, ciclos ou pais ausentes. Isso confirma integridade estrutural, n o separa o clara entre os conceitos. H 20 descri es vazias e 337 com prefixos de metadados de hierarquia; a maioria n o fornece uma defini o editorial que diferencie temas pr ximos.

Nos textos, 94 comandos j estavam vazios; ap s retirar marca o sem conte do, s o 101. H 18 assuntos de origem vazios e uma disciplina de origem vazia. A prepara o sinalizou 148 quest es, sem converter automaticamente os avisos em reprova o. Oito grupos de t tulos se repetem em ramos distintos; o mapeamento de ambiguidades da pol tica abrange 20 IDs, incluindo outras sobreposi es potenciais.

Problema concreto	Consequ ncia e tratamento
Maria da Penha: 4704 / 6724; Drogas: 4708 / 6728; A o Penal: 5063 / 5466.	O mesmo t tulo n o autoriza fundir IDs. Mantive os ramos e encaminhei colis es revis o. Proponho ao editor definir escopo, exemplos e destino can nico quando houver duplica o real.
Q0239 tem comando gen rico; Q0107 concentra informa o no comando.	A unidade de classifica o o texto completo, incluindo alternativas. Enunciado curto, sozinho, n o determina tema nem aus ncia de tema.
Q0099 cont m marca o de Word; Q0078 tem degrada o de OCR; Q0219 depende de contexto ausente.	Removi apenas marca o. Perda de conte do e ambiguidade entram na triagem; reparar o texto exige recuperar a fonte.
Q0180: Busca e Apreens o (5554) versus Prova Ilegal e Prova Il cita (5594).	A auditoria questionou o foco central. Ter o outro tema como extra n o corrige o central. A vers o final ret m a quest o, sem afirmar qual r tulo est juridicamente certo.
Q0024 contrap e n s irm os de teorias criminol gicas.	A diferen a entre irm os conta como erro na regra do case. O experimento mostrou necessidade de fronteiras editoriais claras, mesmo com refer ncia de IA provis ria.

Por que a cobertura baixa

Na v1, das 277 revis es, 232 tinham temas alternativos, 218 confian a abaixo do limiar, 193 revis o solicitada, 60 ambiguidade mapeada e 32 excesso de extras; quatro vieram de corre es de candidatos a **fora**. Os sinais se sobrep em. S 41 casos eram retidos exclusivamente por alternativas, sete apenas pela confian a e um apenas por ambiguidade. Reduzir somente o limiar n o resolveria o gargalo principal.

Dos oito candidatos iniciais a **fora**, uma revis o separada por IA encontrou tema para quatro e os encaminhou a **revisar**; quatro permaneceram fora. Origem em outra disciplina n o bastou para excluir. Essas interven es est o registradas com antes/depois, evid ncias e limita es; n o foram validadas por especialista.

Fontes: diagn stico estrutural, ambiguidades, cobertura v1, revis o de fora.

Previs o com limites expl citos

3. Evid ncia, previs o e rastreabilidade

Congelei a v1 antes da compara o: tr s revisores por IA, em contextos separados e sem sugest es Gemini, cobriram os 78 publicados. A regra de amostrar at 80 restantes resultou em censo: cinco casos do desenvolvimento e 73 restantes. Houve **77/78 = 98,72% de concord ncia com a refer ncia provis ria**, uma diverg ncia (Q0180) e nenhum inconclusivo. Isso n o mede o poss vel erro compartilhado entre IAs. Os textos haviam sido vistos na explora o inicial; n o h conjunto inteiramente intocado.

Q0009, Q0088 e Q0187 t m refer ncias que aceitam dois temas. Trat -las como n o confirmadas produz 74/78 = 94,87%, uma sensibilidade posterior, n o um intervalo estat stico. Em Q0179, uma busca exibiu incidentalmente trecho de gabarito de alternativas; o incidente foi registrado. N o houve acesso aos r tulos tem ticos reservados do case.

Na v2, retive Q0180 por esse achado conhecido. As refer ncias reutilizadas n o tornam os 77 remanescentes uma valida o independente, nem provam precis o de 100%. O segundo passe do 5C teve 22/23 concord ncias pela regra hier rquica, mas s 20/23 estritas e uma diverg ncia: o lote inteiro de propostas foi rejeitado, sem escolher apenas os acertos ap s consultar a refer ncia.

Campo de previsao.txt	Como foi calculado
Precis o prevista: 94,81%.	Julgamento conservador: reserva de quatro poss veis erros, 73/77. As tr s refer ncias m ltiplas e o incidente motivam cautela, mas n o s o quatro erros observados, nem os nicos locais poss veis de erro.
Intervalo de precis o: 89,61% a 100%.	Cen rios assumidos de zero a oito erros: 69/77 a 77/77. Dobrar a reserva julgamento editorial, sem n vel de confian a, calibra o ou evid ncia de que oito seja teto. O resultado real pode ficar abaixo.
Cobertura: 21,45%; intervalo igual ao ponto.	Contagem conhecida: 77/359. Refere-se a este lote, n o pr xima importa o.

Sem hip teses sobre o erro da refer ncia, os limites identific veis da precis o jur dica seriam [0,1]. Por isso, a previs o acima assumidamente subjetiva. Para cumprir 95% neste conjunto, podem existir no m ximo tr s erros; quatro j deixam o resultado em 94,81%. N o ajustei o CSV para fazer a previs o parecer atingir a meta. Extras, decis es de revis o e exclus es n o s o avaliados pela concord ncia do central.

Custo e tempo observados

Piloto v1, lote completo (j inclui piloto v2) e 5C somam 474 tentativas registradas e 13.079.922 tokens conhecidos; 40 tentativas n o informam uso. O lote usa 404 tentativas; o 5C, 50. A conclus o das ltimas 197 quest es levou 87 min 32 s; o 5C, 21 min 48 s, com esperas. Esses tempos de execu o n o medem esfor o humano total. As 20 horas foram planejamento, n o apontamento de horas.

A API foi usada em projeto gratuito, sem ativar faturamento. Consumo Codex, verifica es sint ticas e poss vel chamada interrompida sem recibo ficam fora desses totais; o modelo espec fico dos revisores Codex n o foi registrado nos recibos. N o afirmo custo total zero. C digo, prompts, recibos, interven es e c lculos est o no reposit rio.

Fontes: auditoria v1, trilha v2, evid ncias documentais, previs o completa.

Publicar em escala exige valida o

4. Proposta para 50 mil quest es por semana

Este desenho proposto, n o foi implementado nem homologado. At existir avalia o jur dica independente, operaria em sombra, com aprova o editorial antes da exposi o ao aluno. A confian a autodeclarada e a concord ncia entre IAs n o bastam para liberar publica o em escala.

- **Importar:** preservar original, limpar marca o, detectar duplicatas e conte do incompleto. Usar fila idempotente, limites por projeto, tentativas limitadas e fila de falhas. Versionar modelo, prompt, taxonomia e decis o para revers o.

- **Selecionar candidatos:** combinar busca lexical e embeddings, ancestrais e ramos repetidos. Validar recall@k antes de substituir o cat logo completo. Sem candidatos confi veis, consultar o cat logo ou reter; nunca deduzir **fora** apenas da busca.

- **Decidir e revisar:** LLM estruturado, regras e absten o. Testar classificador treinado ap s acumular r tulos adjudicados; calibrar limiares por ramo em dados separados. N o incluir segundo agente em todo item: o 5C n o demonstrou ganho adot vel.

- **Integrar plataforma:** professor recebe texto, sugest o, alternativas e motivo; corre es s o audit veis. Reporte do aluno entra em triagem por gravidade e alcance, pode suspender a associa o e aciona busca por erros semelhantes; n o altera r tulos automaticamente.

Custo por quest o e capacidade

Tarifas Standard consultadas em 16/10/2026 para Gemini 3.5 Flash-Lite: US$0,30/M tokens de entrada, US$0,03/M de entrada em cache e US$2,50/M de sa da, incluindo racioc nio. F rmula: **[(I - C) 0,30 + C 0,03 + S 2,50] / (1 milh o N)**; cache C j faz parte da entrada I e S inclui racioc nio.

Cen rio de API	US$/item	US$/50 mil	Hip tese e limite
Cat logo atual, com cache	0,0057	283,44	Consumo conhecido das 404 tentativas dividido por 359; cache informado.
Cat logo atual, sem desconto	0,0127	634,27	Mesmo consumo conhecido; entrada inteira tarifa cheia. N o teto de gasto.
Candidatos reduzidos	0,0057	284,62	Hip tese: 4 mil tokens de entrada, 1,5 mil de sa da+racioc nio e 1,15 tentativas/item; sem cache. Ainda n o medido.

Os cen rios n o s o faturas: excluem uso ausente, infraestrutura, embeddings, revis o e auditoria. A recupera o pode reduzir tokens e tamb m o benef cio do cache; a economia precisa ser medida. Na mistura atual, seriam **38.719 revis es/semana**. A dois minutos cada, cerca de 1.291 horas; a US$20/h hipot ticos, s revis o custa US$0,52 por quest o importada. O gargalo editorial. A cota gratuita informada de 500 chamadas/dia n o suporta 50 mil/semana; seria necess rio or amento e cotas pr prios.

Qualidade cont nua e crit rio de libera o

Congelar pol tica e avaliar lote novo com especialistas cegos, adjudica o e amostra probabil stica estratificada por ramo/origem. Estimar precis o dos publicados com pesos amostrais e limite inferior de 95% de confian a pelo menos igual a 95%; inconclusivos entram como n o confirmados. Auditar extras e **fora** separadamente e medir perdas entre retidos. Monitorar semanalmente precis o cobertura, fila/tempo de revis o, custo, falhas e reportes; separar amostra aleat ria de casos priorit rios. Mudan a de modelo, taxonomia ou queda de qualidade exige nova valida o e reten o do segmento afetado.

Fontes: pre os Google, limites por projeto, consumo e hip teses reproduz veis.

Memo ao professor

Assunto: tornar os temas mais claros e proteger o estudo por t pico

Professor(a), examinei 359 quest es. A entrega prop e 77 para publica o, mant m 278 para revis o e deixa quatro fora do recorte por falta de tema adequado. Essa sele o ainda precisa de valida o jur dica: a confer ncia dispon vel foi feita por ferramentas de IA, sem revis o de especialista. Publicar menos foi uma forma de preservar as d vidas, n o uma demonstra o de que todas as publicadas est o certas.

O que encontramos

Algumas quest es misturam v rios assuntos nas alternativas; outras t m texto incompleto ou marcas de uma importa o antiga. Nesses casos, classificar s pela primeira frase induz erro. H tamb m temas com o mesmo nome em lugares diferentes da rvore, e muitas descri es apenas repetem onde o tema est , sem dizer o que ele abrange.

Um exemplo concreto Q0180: a classifica o sugeriu Busca e Apreens o, mas a confer ncia apontou Prova Ilegal e Prova Il cita como poss vel foco principal. Mantive a quest o em revis o. Ela mostra por que precisamos identificar o conhecimento central exigido, e n o apenas o procedimento citado na narrativa.

Mudan as que recomendo nos temas

- **Esclarecer os nomes repetidos.** Lei Maria da Penha aparece nos IDs 4704 e 6724; Drogas, em 4708 e 6728; A o Penal, em 5063 e 5466. Precisamos definir se s o duplica es ou recortes diferentes. Se forem equivalentes, escolher um destino principal e preservar o encaminhamento das associa es antigas; se forem distintos, explicitar a diferen a no nome e na descri o.

- **Escrever crit rios curtos de inclus o e exclus o.** Para cada fronteira problem tica, registrar o que pertence ao tema, o que vai para o tema vizinho e dois exemplos comentados. Come aria por prova versus busca e apreens o, teorias criminol gicas pr ximas e os nomes repetidos.

- **Evitar dep sitos gen ricos de quest es.** Um tema introdut rio deve receber apenas o que cobra a introdu o. Quando a quest o cobra conte do espec fico, precisamos do destino correspondente; quando mistura focos sem predomin ncia, a d vida deve ficar vis vel para revis o.

De que preciso do seu julgamento

Primeiro, decidir o escopo desses pares e a regra para escolher o assunto principal quando h v rias alternativas sobre temas diferentes. Depois, revisar um conjunto novo, separado dos r tulos reservados deste case, incluindo publicadas, retidas e poss veis aus ncias de tema. Os casos duvidosos precisam de justificativa curta e, quando houver discord ncia entre revisores, de uma decis o editorial registrada.

Sugiro come ar pelas fronteiras recorrentes e pelos casos com maior impacto no aluno. A confer ncia regular tamb m deve incluir quest es sorteadas: olhar apenas reclama es n o mostra quantos erros passam despercebidos. Quando o aluno reportar um erro, o professor confirma a corre o e verifica se o mesmo problema aparece em outras quest es do tema.

Resultado esperado: temas que professores e ferramentas consigam distinguir da mesma forma, revis o concentrada nas d vidas reais e publica o acompanhada de qualidade medida. As sugest es acima n o alteraram a rvore fornecida neste case.